

REZUMAT

Aceasta lucrare prezinta trei tehnici de **feature engineering** aplicate pe seriile temporale energetice (consum SUA, pret Spania, productie solara India). Datele brute (timestamp, valoare) NU sunt direct utilizabile de modelele de Machine Learning. Cele 3 tehnici - **encoding ciclic**, **lag features**, **rolling features** - le transforma in coloane informative. Demonstram pe model propriu XGBoost antrenat pe pretul energetic spaniol (34.896 ore, 78 features) ca aceste tehnici aplicate corect duc la $R^2 = 0.968$, depasind LSTM si modelele clasice. Subliniem o capcana tehnica subtila: rolling features fara .shift(1) introduc **data leakage** - feature-ul vede target-ul si modelul 'invata' raspunsul.

PROBLEMA - DE CE FEATURE ENGINEERING?

Pentru ML clasic (XGBoost, RandomForest, regresie), datele de tip serie temporala trebuie transformate intr-un tabel cu coloane informative. Pattern-urile fundamentale ale seriilor energetice sunt: **sezonabilitate orara** (consum mare seara, mic noaptea), **ciclu saptamanal** (fabricile lucreaza luni-vineri), **autoregresivitate** (pretul peste o ora $\approx$ pretul actual), **trend si volatilitate recenta**. Toate aceste pattern-uri sunt ASCUNSE in (timestamp, valoare) - trebuie extrase explicit. Solutia: cele 3 tehnici de mai jos.

CELE 3 TEHNICI

TEHNICA	PROBLEMA	SOLUTIA	FEATURE-URI CREATE
1. Encoding ciclic	Ora 23 si 0 sunt vecine pe ceas dar la distanta 23 in reprezentare liniara.	Asezam timpul pe cerc trigonometric (sin, cos).	hour_sin, hour_cos month_sin, month_cos dow_sin, dow_cos
2. Lag features	Modelul nu are 'memorie' a trecutului.	Adaugam coloane cu valoarea de acum 1h, 24h, 168h.	price_lag_1 price_lag_24 price_lag_168
3. Rolling features	Un singur punct din trecut poate fi atipic.	Medie / deviatie pe fereastră alunecătoare CU .shift(1).	price_roll_mean_3 price_roll_mean_24 price_roll_std_24

ENCODING CICLIC: MATEMATICA

$$\text{hour_sin} = \sin(2\pi \cdot h / 24) \quad \text{hour_cos} = \cos(2\pi \cdot h / 24)$$

Cele 2 coloane (sin, cos) identifica UNIC fiecare ora ca un punct pe cercul trigonometric. Distanța euclidiană între ora 23 și ora 0 pe cerc devine 0.27 (mica și naturală), nu 23. Aceeași tehnică funcționează pentru zi-săptămânii, luna, ziua-din-an.

ATENȚIE: ROLLING FEATURES SI DATA LEAKAGE

Detaliul tehnic cel mai important al lucrării. Implementarea naivă a rolling features introduce data leakage - feature-ul include în calcul valoarea pe care vrem să o prezicem.

GRESIT (data leakage)	CORECT (cu shift)
<pre>df['roll_mean_3'] = \ df['pret'].rolling(3).mean()</pre>	<pre>df['roll_mean_3'] = \ df['pret'].shift(1).rolling(3).mean()</pre>
La momentul t, feature include valoarea t. R^2 fals = 0.94 Model 'invatata' raspunsul.	La momentul t, feature foloseste DOAR t-1, t-2, t-3. R^2 cinstit = 0.75 Model valid in productie.

REZULTATE EMPIRICE - PRETUL ENERGETIC SPANIA

Aplicand cele 3 tehnici de feature engineering (cu `.shift(1)` corect aplicat) pe setul ENTSOE (34.896 ore, 78 features), am antrenat 7 modele cu validare cronologica (TimeSeriesSplit, 5 folds):

MODEL	$R^2 \uparrow$	RMSE $\downarrow$ (EUR/MWh)	MAPE $\downarrow$	OBSERVATII
LinearRegression	0.947	2.64	3.49%	Baseline solid
Ridge	0.948	2.63	3.46%	Regularizare L2
Lasso	0.956	2.40	2.93%	Regularizare L1 - elimina features
RandomForest	0.963	2.22	2.71%	Ensemble nelinear
XGBoost	0.968	2.07	2.57%	CASTIGATOR
XGBoost + Optuna	0.966	2.12	2.65%	Tuning bayesian (5 trials demo)
LSTM (mod demo)	-1.12	20.66	60%	Date insuficiente in demo

Toate modelele clasice obtin R^2 peste 0.94 - dovada ca cele 3 tehnici aplicate corect au creat features extrem de informative. Diferenta intre cel mai slab (LinearRegression) si cel mai bun (XGBoost) este **doar 0.02 in R^2** - ceea ce conteaza nu este selectia modelului, ci calitatea feature engineering-ului.

CONCLUZII

1. Feature engineering > selectia modelului. Pe time series, calitatea features-urilor face mai mult decat ajustarea fina a modelului. Toate cele 6 modele clasice obtin scoruri excelente daca features-urile sunt construite corect.

2. Detaliile tehnice decid intre cinstit si fals. Un simplu `.shift(1)` inainte de rolling este diferenta intre un model care arata bine pe test si esueaza in productie, si un model care performeaza consistent. Aceasta capcana este subestimata in tutoriale.

3. Tehnicile sunt universale. Encoding ciclic, lag si rolling features functioneaza la fel pe consum (SUA), pret (Spania) si productie solara (India). Sunt un fundament metodologic care se transfera intre domenii. In pasul urmator al lucrării voi aplica acelasi pipeline si pe sesiunea 3 (productia solara India).

Date utilizate: ENTSOE - operatorul european de transport energie (pret Spania); PJM Interconnection (consum SUA); Kaggle Solar Power Generation (productie India). **Cod:** Python (pandas, scikit-learn, XGBoost) - reproductibil in github.com/diana-nenu.

Contact: Diana Nenu · diana_nenu@yahoo.com · Universitatea Titu Maiorescu, Master DSAI