

## REZUMAT

Aceasta lucrare prezinta metoda **SHAP (SHapley Additive exPlanations)**, un cadru matematic riguros pentru interpretarea modelelor de Machine Learning, ale carui radacini se afla in **teoria jocurilor cooperative** formulata in 1953 de Lloyd Shapley. Demonstram cum o constructie teoretica veche de peste 65 de ani, recunoscuta cu Premiul Nobel pentru Economie in 2012, este utilizata astazi pentru a explica predictiile modelelor de gradient boosting si ale retelelor neurale. Aplicam metoda pe un model propriu XGBoost antrenat pentru predictia pretului energetic in Spania ( $R^2 = 0.968$ ), obtinand atat importanta globala a celor 78 de features cat si decompunerea predictiilor individuale, validand astfel ca modelul invata pattern-uri cauzale reale (autoregresivitate, ciclu saptamanal, impact eolian).

## CONTEXT - 65 DE ANI DE LA SHAPLEY LA SHAP

**1953:** Lloyd Shapley publica "*A Value for n-Person Games*" - propune o solutie axiomatica pentru impartirea cinstita a castigului intr-o coalitie de jucatori cooperativi.

**2012:** Shapley si Roth primesc **Premiul Nobel pentru Economie** pentru aplicatiile teoriei in mecanism design si in piete de potriviri stabile (alocare de elevi, transplant de rinichi).

**2017:** Lundberg si Lee (Univ. of Washington) publica "*A Unified Approach to Interpreting Model Predictions*" la NeurIPS - aplica formula Shapley pentru a explica deciziile retelelor neurale si XGBoost, fondand SHAP. Astazi unul dintre cele mai citate articole din ML interpretabil.

## CELE 4 AXIOME DE CORECTITUDINE

Shapley a demonstrat ca exista o **unica** formula matematica de alocare a contributiilor intr-o coalitie care satisface simultan urmatoarele patru axiome:

|                      |                                                                                                                 |
|----------------------|-----------------------------------------------------------------------------------------------------------------|
| <b>1. EFFICIENCY</b> | Suma contributiilor = valoarea totala creata. $\sum \phi_i = v(N)$                                              |
| <b>2. SYMMETRY</b>   | Jucatori echivalenti primesc contributii egale. $v(S \cup \{i\}) = v(S \cup \{j\}) \Rightarrow \phi_i = \phi_j$ |
| <b>3. DUMMY</b>      | Jucatorii inutili primesc contributie nula. $v(S \cup \{i\}) = v(S), \forall S \Rightarrow \phi_i = 0$          |
| <b>4. ADDITIVITY</b> | Pentru jocuri combinate, contributiile se aduna. $\phi_i(v+w) = \phi_i(v) + \phi_i(w)$                          |

## FORMULA VALORII SHAPLEY

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} (|S|! \cdot (n - |S| - 1)! / n!) \cdot [v(S \cup \{i\}) - v(S)]$$


Termenul  $v(S \cup \{i\}) - v(S)$  = contributia marginala a lui i la coalitia S. Coeficientul  $|S|! \cdot (n - |S| - 1)! / n!$  = probabilitatea ordinii de aderare. Suma = media peste toate coalitiile posibile ( $2^{n-1}$  subseturi). **Complexitate exacta:  $O(2^n)$**  - rezolvata in practica prin TreeSHAP cu complexitate polinomiala  $O(T \cdot L \cdot D^2)$  pentru modele bazate pe arbori.

## TRANSLATIA IN CONTEXT MACHINE LEARNING

| TEORIA JOCURILOR (1953)       | MACHINE LEARNING (2017)              |
|-------------------------------|--------------------------------------|
| Jucator i                     | Feature i (ex: price_lag_1)          |
| Coalitia $S \subseteq N$      | Subset de features                   |
| Functia caracteristica $v(S)$ | Predictia conditionata $E[f(x)   S]$ |
| Valoarea Shapley $\phi_i$     | Valoarea SHAP a feature-ului         |

## APLICATIE PROPRIE - PRETUL ENERGETIC SPANIA

Am antrenat un model XGBoost (200 arbori, max depth 6, learning rate 0.05) pe setul de date ENTSOE - pretul energetic spaniol pe 4 ani (34.896 ore, 78 features). Performanta de validare:  $R^2 = 0.968$ ,  $RMSE = 2.07 \text{ EUR/MWh}$ ,  $MAPE = 2.57\%$ . Am calculat valorile SHAP cu algoritmul **TreeSHAP** exact (NeurIPS 2017) folosind *API-ul native XGBoost* (`booster.predict(pred_contribs=True)`) - solutie ingineareasca proprie pentru incompatibilitatea actuala intre shap 0.49 si XGBoost 3.x.



Top 15 features SHAP - importanta globala ([SHAP value] mediu in EUR/MWh)

## INSIGHTURI CHEIE

### Autoregresivitate puternica:

price\_lag\_1 domina cu impact mediu 9.09 EUR/MWh - de 6x mai mult decat al 2-lea feature.

### Ciclu saptamanal:

price\_lag\_168 (= 7 zile) prezent in top, indicand pattern de business vs weekend.

### Sezonalitate intra-zi:

hour\_cos / hour\_sin (encoding ciclic) contribuie negativ (scad pretul in anumite ore).

### Validare cauzala:

wind\_speed apare in top 15 - vantul puternic scade pretul (oferta eoliana suplimentara).

## CONCLUZII

**1. Conexiunea matematica e profunda** - SHAP nu este un trick inventat in 2017, ci aceeasi matematica pentru care Shapley a primit Nobelul, reinterpretata. Garantia ca putem deschide 'cutia neagra' a modelelor moderne are radacini intr-o lucrare publicata in 1953.

**2. Aplicabilitate practica imediata** - pe XGBoost-ul propriu ( $R^2 = 0.968$  pe pretul Spania), SHAP confirma ca modelul foloseste pattern-uri reale: autoregresivitate, sezonalitate, ciclu saptamanal si impact eolian. Validare cauzala, nu doar statistica.

**3. Fundamentul componentei LLM** - in arhitectura platformei propuse in disertatie, valorile SHAP devin *materia prima* pe care un Large Language Model o transforma in insighturi in limbaj natural pentru operatorul energetic, completand bucla decizionala *predictiv* → *interpretabil* → *comunicat*.

**Referinte cheie:** Shapley L.S. (1953) *A Value for  $n$ -Person Games*; Lundberg S.M., Lee S.-I. (2017) *A Unified Approach to Interpreting Model Predictions*, NeurIPS; Lundberg S.M., Erion G., Lee S.-I. (2020) *From Local Explanations to Global Understanding with Explainable AI for Trees*, Nature Machine Intelligence.

**Contact:** Diana Nenu - diana\_nenu@yahoo.com - Universitatea Titu Maiorescu, Master DSAI